

大模型后训练新范式OPD：起源、发展路线与当今现状

智猩猩Pro 2026年5月22日 20:30 北京

AgenticAICon

2026中国AI智能体大会

2026.7.2-3 杭州 主办：智东西 联合主办：智猩猩

扫码咨询

日期	时段	分会场一	主会场	分会场二
7.2	上午	开幕式		
	下午	Coding Agent 技术研讨会 (08:00-12:00)	企业级AI智能体 专题论坛	Computer-Use Agent 技术研讨会 (08:00-12:00)
	晚上	交流晚宴		
7.3	上午	自进化智能体 技术研讨会 (08:00-12:00)	AI智能体 产品创新论坛	多智能体协同 技术研讨会 (08:00-12:00)
	下午	深度研究智能体 技术研讨会 (08:00-12:00)	Agent Harness 技术研讨会 (08:00-12:00)	Agent Skills 技术研讨会 (08:00-12:00)

王琰

腾讯大语言模型部 Frontier团队专家研究员

肖仰华

复旦大学教授 上海市数据科学重点实验室主任

林炜哲

华为中央研究院 先进计算与存储实验室 大模型算法专家

胡梦康

香港大学在读博士 Evolvent AI创始人

张凡瑞

中国科大与上海创智学院联培博士 通义实习研究员

更多嘉宾 即将揭晓

7月2-3日，复旦大学教授、上海市数据科学重点实验室主任肖仰华，腾讯大语言模型部Frontier团队专家研究员王琰，华为中央研究院先进计算与存储实验室大模型算法专家林炜哲，香港大学在读博士、Evolvent AI 创始人胡梦康，中国科大与上海创智学院联培博士、通义实习研究员张凡瑞等嘉宾将在2026中国AI智能体大会带来主题报告。

作者：獭獭獭

地址：<https://zhuanlan.zhihu.com/p/2037285722151989443>

经授权发布，如需转载请联系原作者

综合来源（2026-05-14 重新核验）：Thinking Machines Lab Blog · Qwen3 Technical Report · MiMo-V2-Flash Technical Report · OPD/G-OPD/MAD-OPD 等 arXiv 论文。原文中未能核验的 GLM-5 Cross-Stage OPD、DeepSeek-V4 OPD、Qwen3.5 OPD 等说法已删除或降级。引用修订原则：只把题名、链接、时间能相互匹配的论文列为正式文献；模型报告若未在公开材料中明确支持 OPD 结论，只作为相关背景，不作为 OPD 证据。

Preliminary:
Forward KL 与 Reverse KL——
00 OPD 的理论根基

本节综合自 Emiliano Penaloza et al., “Privileged Information Distillation for Language Models” (arXiv:2602.04942, 2026) 及其配套博客。该工作提出了 π -Distill

方法，同时也是理解 OPD 中 Forward KL vs Reverse KL 的最佳入门材料。

为什么 KL 方向是 OPD 一切讨论的起点

OPD 的目标是让学生模型的输出分布逼近教师。但”逼近”有两种截然不同的方式，取决于 KL 散度的方向：

Forward KL: $KL(\text{教师} \parallel \text{学生}) \rightarrow \text{Mode-covering}$ (覆盖模式)

Reverse KL: $KL(\text{学生} \parallel \text{教师}) \rightarrow \text{Mode-seeking}$ (寻找模式)

这个选择决定了学生学到什么、丢掉什么、付出什么代价。OPD 用 Reverse KL 不是随意的——它是从 RL-as-inference 框架中数学推导出来的必然结果。

RL as Variational Inference: Reverse KL 从哪里来

RL 的标准目标是最大化期望奖励：

$$\pi^* = \arg \max_{\pi} E_{y \sim \pi(\cdot|x)} [R(y, x)]$$

但在实践中，直接用这个目标会导致策略熵崩塌 (entropy collapse) ——模型把所有概率质量堆到一个高奖励输出上，失去泛化能力。

RL-as-inference 换个视角看这个问题。定义目标分布 π^* 为一个 reward-tilted 分布：

$$\pi^*(y|x) \propto \pi_{\text{ref}}(y|x) \cdot \exp(R(y,x) / \beta)$$

其中 β 是 KL 正则化系数， π_{ref} 是初始参考策略 (通常是 base model 或 EMA)。

直观理解： π^* 是一个”理想分布”——它在 π_{ref} 的基础上，给高奖励的输出加权，但不偏离参考策略太远。 β 越小，奖励的影响越大； β 越大，越接近参考策略。

问题是 π^* 的归一化常数 $Z(x)$ 无法计算 (需要对所有可能的输出求和)。所以我们参数化一个近似策略 π_{θ} 去逼近 π 。关键在于：**我们只能从 π_{θ} 采样，不能从 π 采样**——这决定了只能用 Reverse KL：

$$\text{Reverse KL: } KL(\pi_{\theta} \parallel \pi^*) = E_{y \sim \pi_{\theta}} [\log \pi_{\theta}(y|x) - \log \pi^*(y|x)]$$

↑
期望在 π_{θ} (可采样) 上取

展开并去除常数项，得到标准 KL 约束的 RL 目标：

$$\max_{\theta} E_{y \sim \pi_{\theta}} [R(y, x)] - \beta \cdot KL(\pi_{\theta} \parallel \pi_{\text{ref}})$$

↑ 最大化奖励 ↑ 不偏离参考策略太远

这里有一个对理解 OPD 至关重要的点：RL 的 KL penalty 项 $KL(\pi_\theta \parallel \pi_{\text{ref}})$ 本质上是 Reverse KL——它把 π_{ref} 当作“目标”（类似于 OPD 中的教师）。当 $\beta > 0$ 时，策略在奖励最大化和“不远离参考”之间平衡。

Forward KL = SFT (Off-Policy 蒸馏)

定义：

因为 π_T 固定，最小化 Forward KL 等价于最大化教师样本上的对数似然：

这就是标准 SFT (Supervised Fine-Tuning)。

Forward KL 的行为——Mode-Covering (覆盖模式)：

Forward KL 惩罚学生对教师任何 mode 分配过低概率的行为。

教师有 A (60%)、B (30%)、C (10%) 三个 mode。Forward KL 逼迫学生覆盖 A、B、C 全部三个 mode，即使其中某些对最终任务无用。→ 学生分布“摊大饼”，在高维 token 空间中扩散到教师的整个支撑集。→ 优点：多样性高。缺点：学到教师的低质量/噪声输出。

核心风险：学生输出教师不常输出的 token——在 LLM 生成场景中，这意味着学生可能生成教师几乎不会生成的序列，导致事实性错误 (hallucination)。

为什么 OPD 不用 Forward KL：Forward KL 的期望在教师分布上取 → 训练数据必须来自教师 → Off-Policy → 学生推理时走的是自己的分布，不是教师的 → distribution mismatch → compounding error。

Reverse KL = Self-Distillation / OPD (On-Policy 蒸馏)

定义：

Reverse KL 的行为——Mode-Seeking (寻找模式)：

Reverse KL 只需要学生抓住教师最确定的那个 mode。

教师有 A (60%)、B (30%)、C (10%) 三个 mode。Reverse KL 允许学生把所有概率质量堆到 A 上——对 B 和 C 只给出微量概率。惩罚 = 学生概率 $\times \log(\text{学生}/\text{教师})$ ：学生对 C 给低概率 $\rightarrow$ 乘以前面的低概率 $\rightarrow$ 惩罚近乎零。 $\rightarrow$ 学生”挑选”教师最容易拟合的 mode 进行精确拟合。 $\rightarrow$ 优点：精确、稳定、不学噪声。缺点：可能挑到低奖励的 mode (非全局最优)。

为什么 OPD 必须用 Reverse KL：

1. 采样约束：OPD 的期望必须在学生分布上取（学生自己生成 rollout）——只有 Reverse KL 能做到
2. On-Policy：学生在自己实际犯错的位置被纠正 $\rightarrow$ 无 distribution shift
3. Mode-Seeking 是 feature 不是 bug（在特定场景下）：教师的低概率 mode 往往是噪声/错误 $\rightarrow$ Reverse KL 天然过滤
4. 与 RL 统一：Reverse KL 让 OPD 可以直接嵌入 RL 训练管线（同一个 loss 形式）

Forward KL vs Reverse KL：直观对比

可视化直觉（来自 Penaloza et al. 博客的简化 reward space 可视化）：

Forward KL (SFT):

教师分布: 
 mode A mode B mode C

学生分布: 
 ↑ 覆盖全部 mode, 但每个都不精确 ↑

Reverse KL (OPD):

教师分布: 
 mode A mode B mode C

学生分布: 
 ↑ 只追求 mode A, 但精确拟合 ↑

从 Reverse KL 到 Reward-Tilted Distillation

纯 Reverse KL 自蒸馏有一个核心问题：学生倾向于拟合教师最容易的那个 mode，但这个 mode 可能对应低奖励（即教师也经常犯错的那个输出模式）。

解决方法——Reward-Tilted Reverse KL (Penaloza et al., 2026; Shenfeld et al., 2026):

$$\pi_{*_tilted}(y|x) \propto \pi_T(y|x) \cdot \exp(R(y,x) / \beta)$$

↑
在教师分布上乘以奖励的指数项

目标变为：

$$\max_{\theta} \quad E_{\{y \sim \pi_{\theta}\}}[R(y,x)] - \beta \cdot KL(\pi_{\theta} || \pi_T)$$

↑ 往高奖励区域推 ↑ 但不偏离教师

这就是 π -Distill、G-OPD/ExOPD 以及 MiMo-V2-Flash 这类 reward-tilted / multi-teacher OPD 方案的理论背景。原文把同一脉络扩展到 DeepSeek-V4/GRM，但该引用未能核验，已移除。

与标准 RL 的关键区别：

- 标准 RL：KL penalty 的参考是静态的 π_{ref} (base model)
- Reward-Tilted OPD：KL penalty 的参考是动态的 π_T (teacher model，可以随着训练改善)

为什么这很重要

所有 OPD 变体——从最基础的 Agarwal et al. (2023) 到 MiMo-V2-Flash MOPD、G-OPD/ExOPD、MAD-OPD——都是在 Forward KL 和 Reverse KL 之间的光谱上做选择：

实践中（Qwen3、MiMo-V2-Flash、G-OPD 等已核验公开材料中的常见模式）：

1. Phase 1: Forward KL (SFT on teacher data) → 初始化，扩展学生支撑集
2. Phase 2: Reverse KL (OPD on student rollouts) → 精细化，mode-seeking 到最优解
3. Phase 3 (可选)：Reward-Tilted Reverse KL → OPD + Outcome Reward

01 雏形：OPD 的思想源头

1.1 DAGGER (2010–2011) ——交互式模仿学习

论文：A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning 作者：Stéphane Ross, Geoffrey J. Gordon, Drew Bagnell (CMU) 时间：AISTATS 2011 (arXiv 2010)

核心问题：行为克隆（Behavioral Cloning）中，学生策略在专家示范数据上训练 → 部署时遇到训练分布外的状态 → 一个错误导致连锁崩塌（compounding error）。

解决方案——DAGGER (Dataset Aggregation)：

1. 学生策略 rollout，收集自己生成的状态序列
2. 专家对学生的每一步状态标注正确动作
3. 将标注数据加入训练集
4. 迭代 1–3

关键洞察：学生必须在自己诱导的状态分布上被纠正，而非在专家的状态分布上。这正是 13 年后 OPD 的核心逻辑。

1.2 GKD / On-Policy Distillation of Language Models (2023–2024) ——移植到 LLM

论文：On-Policy Distillation of Language Models: Learning from Self-Generated Mistakes

作者: Rishabh Agarwal, Nino Vieillard 等 (Google DeepMind) 时间: arXiv 2023.06 → ICLR

2024 链接: <https://arxiv.org/abs/2306.13649>

核心贡献——GKD (Generalized Knowledge Distillation) :

将 DAGGER 的 on-policy 范式从 imitation learning 移植到 LLM 知识蒸馏：

概念	DAGGER (2011)	GKD / OPD (2023)
领域	Imitation learning (机器人/RL)	Knowledge distillation (LLM)
学生	Learner policy	小模型 (student)
教师	Expert demonstrator	大模型 (teacher)
On-policy 数据	Learner rollout states	Student 自生成的 token 序列
反馈	Expert 标注正确动作	Teacher 提供 logit probabilities
解决的问题	Distributional shift	Train-inference distribution mismatch

三个关键创新：

- 1. On-policy 采样：学生自己生成序列，而非学习教师生成的数据集
- 2. 灵活散度：支持 reverse KL、Jensen-Shannon 等多种散度（标准 KD 仅用 forward KL）
- 3. RL 兼容：GKD 可自然嵌入 RLHF 训练管线

与标准 Off-Policy KD 的本质区别：

Off-Policy KD (传统) :
教师生成数据 → 固定数据集 → 学生模仿
问题：学生推理时遇到的状态 不在数据集中 → compounding error

OPD / GKD:
学生自己生成 → 教师对学生每一步打分 → 学生被纠正
优势：学生始终在自己的分布上被评估 → 无 distribution shift

1.3 MiniLLM (2023) ——Reverse KL 的引入

论文: MiniLLM: Knowledge Distillation of Large Language Models 作者: Yuxian Gu 等 (清华) 时间: arXiv 2023.06 → ICLR 2024

从另一个角度论证了 on-policy + reverse KL 的必要性：

- Forward KL (标准 KD)：mode-covering——学生必须覆盖教师所有输出模式，包括噪声和教师不确定的低概率区域
- Reverse KL (MiniLLM/OPD)：mode-seeking——学生只需学到教师最确定的推理路径，避免被教师的噪声分布污染

OPD 的 loss 函数由此定型：

发展路线：

02 从学术论文到工业范式

时间线总览：

2010–2011 DAGGER (Ross et al.)

└ 交互式模仿学习的思想奠基

2023.06 Agarwal et al. / Gu et al. 分别投稿 arXiv

└ OPD 与 MiniLLM 几乎同时提出

2024.05 ICLR 2024 正式发表

└ OPD 作为独立研究方向确立

2024.07 Google Gemma 2 技术报告 (arXiv:2408.00118)

└ 公开报告明确使用大教师蒸馏 9B/2B；这里作为工业 KD 背景，不再强称为 OPD 首例

2025.05 Qwen3 技术报告 ← 分水岭

└ 首个系统性阐述 OPD 的头部实验室报

└ Strong-to-Weak 两阶段蒸馏：SFT → OPD

└ 仅需 RL 的 1/10 GPU 时间达到可比推理能力

2025.10 Thinking Machines Lab Blog

└ 最全面的 OPD 工程实践指南

└ 数学推理 9-30× 算力节省 + 个性化/持续学习

2026.01 MiMo-V2-Flash (小米, arXiv:2601.02780) 开源

└ MOPD: 多教师 OPD / outcome reward 组合的公开工程案例

2026.02 学术论文爆发期开始

└ Privileged Information Distillation / G-OPD / On-Policy Context Distillation

└ DeepMind 内在维度量化 CoT → OPD 质量评估

└ CODI / Coconut 在 latent space reasoning 取得进展

2026.03 Entropy-Aware OPD + Revisiting OPD 上线

└ 系统化 OPD 三类失败模式 + 修复方案2026.04 里程碑月

└ 论文 5 (Tsinghua): OPD 机制深度分析, 分布不可区分性, 97-99% 概率质量

└ Lightning OPD (arXiv:2604.13010): 完全离线 OPD

└ Demystifying OPD / SCOPE: 训练稳定性与采样策略改进

└ Qwen3.5-0mni 技术报告存在, 但不再作为 OPD 证据引用

2026.05 MAD-OPD (arXiv:2605.01347) + Missing Old Logits (arXiv:2605.12070)

关键转折点详解

转折点 1: Qwen3 (2025.05) ——OPD 工业化的起点

关键数据: OPD 仅需完整 RL pipeline 的 $1/10$ GPU 时间, 达到可比推理性能。
AIME'24 74.4% @ 1,800 GPU hours vs RL 67.6% @ 17,920 GPU hours。

转折点 2：MiMo-V2-Flash (2026.01) ——多教师 OPD

小米将单教师 OPD 扩展为 MOPD (Multi-Teacher On-Policy Distillation)：

Stage 1: SFT → 基础指令遵循Stage 2: 独立训练 5 个专家教师 (Code Agent / Search Agent / Math / General Reasoning / Safety) Stage 3: MOPD
→ 学生从自身分布采样, 5 个领域教师分别提供 token 级监督 Advantage
$$= \sum_i w_i \times \text{KL}(\pi_{\text{domain}_i} || \pi_{\text{student}}) + \alpha \times \text{ORM}$$

核心发现：在 logit 空间而非参数空间中整合能力——避开了 weight merge 中常见的能力干扰。学生甚至超越最强单教师：AIME 2025 94.1% vs teacher 93.9%。

已降级：GLM-5 / DeepSeek-V4 / Qwen3.5 相关 OPD 叙述

原稿把 GLM-5、DeepSeek-V4、Qwen3.5 写成 OPD 工业化转折点，但逐条核验后存在硬伤：

原说法	核验结果	本文处理
GLM-5 = Cross-Stage OPD, 原错误 ID 2512.16173	2512.16173 实际是物理/材料方向论文；GLM-5 正确条目为 2602.15763, 但公开 arXiv 条目未能支撑 Cross-Stage OPD 细节	删除该转折点，不再作为 OPD 证据
DeepSeek-V4 = OPD 替代 mixed RL, 原错误 ID 2604.16296	2604.16296 实际是代数几何论文；未找到可核验的 DeepSeek-V4 OPD 技术报告条目	删除该转折点
Qwen3.5 / Qwen3.5-Omni = OPD 后训练	2604.15804 是 Qwen3.5-Omni 技术报告，但 arXiv 条目本身不能支撑“OPD 第二阶段训练”这一具体说法	保留为相关模型报告时需单独注明，不进入 OPD 证据链

03 当今发展现状

3.1 OPD 是后训练中的重要分支，但不能泛化到所有模型报告

核验后的稳妥判断是：OPD 已经从 ICLR 2024 的研究框架扩展到 Qwen3、MiMo-V2-Flash 以及一批 2026 年 arXiv 改进论文；但“GLM-5、DeepSeek-V4、Qwen3.5 都采用 OPD”这类说法当前证据不足，不能再作为本文结论。

已核验 OPD 论文中反复出现的动机：

维度	Mixed RL	OPD
反馈密度	常见为 outcome/process reward，粒度较稀疏	教师 token distribution / logits 可提供更密集监督
训练分布	容易出现 off-policy 或数据分布偏移	学生 rollout 上接受教师反馈，直接覆盖学生会犯错的位置
目标形态	奖励、KL、value/advantage 估计共同作用	reverse KL / generalized KL 形式更接近“模仿教师局部分布”
成本收益	依赖探索和 reward 评估成本	在 Qwen3 等报告中显示可显著降低训练成本，但结论需限定到具体实验设置
风险	reward hacking、探索不稳定	mode collapse、teacher-student thinking pattern 不兼容、长序列崩塌

3.2 当前主流 OPD 变体

变体	提出者	核心思路	适用场景
Standard OPD	Agarwal et al. (ICLR 2024)	单教师 → 单学生，token 级 reverse KL	通用能力迁移
Strong-to-Weak OPD	Qwen3 (2025)	两阶段：SFT 初始化 + OPD fine-tune	大模型蒸馏小模型
Multi-Teacher OPD (MOPD)	MiMo-V2-Flash (arXiv:2601.02780, 2026.01)	多领域专家教师，logit 空间加权融合	整合多个专项能力
G-OPD / ExOPD	Yang et al. (arXiv:2602.12125, 2026.02)	引入 λ 与 π_{ref} ，把标准 OPD 推广为可外推的 KL-constrained RL	超越教师边界 / strong-to-weak 蒸馏
MAD-OPD	arXiv:2605.01347 (2026.05)	多教师辩论驱动的 OPD，突破单教师能力天花板	Agentic 任务
Lightning OPD	arXiv:2604.13010 (2026.04)	完全离线 OPD，预计算教师 logits	追求训练速度
Demystifying OPD	arXiv:2604.08527 (2026.04)	分析 length inflation 与稳定化策略	训练稳定性
SCOPE	arXiv:2604.10688 (2026.04)	答对/答错轨迹差异化加权	样本效率

3.3 学术界的核心发现（2026 年集中爆发）

发现	来源	核心结论
OPD 三类失败模式	Fu et al. (2026.03)	不平衡单 token 信号、教师引导在 unknown prefix 不可靠、tokenizer 不匹配
分布不可区分性	论文5 (2026.04)	同家族 7B 和 1.5B 在学生视角下分布不可区分——更大≠更好教师
97-99% 概率质量	论文5 (2026.04)	OPD 梯度信号源集中在 ~3% 的共享 token——token 空间对齐天然受限
Thinking-Pattern 必须兼容	论文5 (2026.04)	OPD 成功的首要条件不是 benchmark 分数高，而是思维模式 overlap
长序列崩塌	论文5 (2026.04)	教师准确率优势从 +0.37 (1K) 退化到 +0.02 (16K)；崩塌从后往前传播
Reverse KL Mode Collapse	论文7,8 (2026.03)	学生只学教师最确定的那条路径，失去推理多样性
$\beta=1$ 限制了 OPD 表现力	论文12 (2026.02)	OPD 是 $\beta=1$ 的 KL-constrained RL 特例——奖励和 KL 必须等权重
学生可以超越教师	论文12 (2026.02)	ExOPD ($\lambda>1$) 通过 reward extrapolation 突破教师能力边界——唯一方案
参考模型选择关键	论文12 (2026.02)	Reward Correction: 用教师 pre-RL base 作为 π_{ref} 提供更准确奖励信号

异步 RL 中 old logits 缺失	论文13 (2026.05)	训练-推理差异 + 策略陈旧→重要性比率语义分解失效；插值 proxy 只是重参数化裁剪边界
PPO-EWMA 低成本修复	论文13 (2026.05)	EMA 参考策略+陈旧感知衰减+自动重置→性能接近 exact old-logit recovery，开销远低于 Snapshot
Small Model Learnability Gap	论文3 (ACL 2025)	≤3B 模型从长 CoT 蒸馏反而退步
Distribution Shift 伤害 CoT	论文6 (2025.06)	首次理论证明：分布偏移下 CoT 比不推理更差
内在维度度量 CoT	DeepMind (2026.02)	LoRA 微调所需最小参数量与 OOD 泛化相关性 0.93，远超长度

3.3.1 论文5 详解：OPD 的机制、条件与边界

论文：Li et al. (Tsinghua NLP), “Rethinking On–Policy Distillation of Large Language Models: Phenomenology, Mechanism, and Recipe” 链接：

<https://arxiv.org/abs/2604.13016> | 代码: <https://github.com/thunlp/OPD> 规模: 30 页, 23 张图, 2026 年 4 月

这是迄今为止对 OPD 训练动力学最系统的实证研究。以下是其五个核心发现的详细展开。

发现一：OPD 成功的两个必要条件

条件 1：思维模式兼容（Thinking–Pattern Consistency）

学生和教师必须共享兼容的”思维模式”——由 top-k token 分布的 Overlap Ratio 衡量：

$$\text{Overlap Ratio} = |S_t^p \cap S_t^q| / k$$

其中 S_t^p = 学生在 prefix 下的 top-k token 集合
 S_t^q = 教师在 prefix 下的 top-k token 集合

实验证据：Qwen3-1.7B-Base 学生 × 两个 Qwen3-4B 教师：

教师类型	Benchmark 分数	Thinking Pattern	OPD 结果
GRPO 训练	相近	与学生兼容	✅ 成功
Non-thinking	相近	与学生差异大	❌ 失败

核心洞察：benchmark 分数高 ≠ 好老师。overlap ratio 才是预测 OPD 成败的关键指标。

条件 2：教师必须有真正的新能力

即使思维模式一致且 benchmark 分数更高，教师必须提供学生在训练中未见过的能力。在两个模型家族（DeepSeek + Qwen）上验证：

核心洞察：更高 benchmark 分数可能只反映”对相同数据的拟合程度不同，而非真正的新能力”。

发现二：逆蒸馏实验——分布不可区分性（最令人警醒的发现）

实验设计：用 JustRL-1.5B（经 RL 训练的强大 1.5B）作为学生，逆向蒸馏到更弱的教师。

结果 1：蒸馏到 R1-Distill-1.5B（学生自己 RL 前的 checkpoint）→ 学生退化到几乎精确等于 RL 前的性能——”移除了 RL 获得的所有增益”

结果 2：蒸馏到 R1-Distill-7B（同家族更大的模型，benchmark 分数更高）→ 训练轨迹与蒸馏到 1.5B 教师几乎完全相同

结论： R1-Distill-1.5B 和 R1-Distill-7B 在学生视角下是分布不可区分的（distributionally indistinguishable）。因为 OPD 的 reverse KL 发生在 student-visited states 上——两个教师在这些状态上诱导出几乎相同的局部目标分布。

三层含义：

1. OPD 本质上学的是思维模式——会主动获取教师模式并覆盖学生自己的
2. Benchmark 性能不能预测 OPD 结果——7B 分数更高但蒸馏无增益
3. 更高 benchmark 分数可能只是”对相同数据的过拟合”，不是真正的能力差异

发现三：Token 级机制——97-99% 概率质量的秘密

对比成功 OPD vs 失败 OPD 的动态指标：

成功 OPD (R1-Distill-1.5B ← JustRL-1.5B)：

- Overlap Ratio 从 ~72% → ~91%（持续上升）
- Entropy Gap 持续缩小
- Overlap-Token Advantage 趋向零

失败 OPD (R1-Distill-1.5B ← R1-Distill-7B)：

- Overlap Ratio 停滞（从一开始就低）
- Entropy Mismatch 从始至终存在

最关键的发现：交集 token 承载了师生双方 97-99% 的总概率质量（整个训练过程中保持）。

这意味着 OPD 的梯度信号几乎完全来自 ~3% 的共享高频 token。其余 97%+ 的 token 不参与学习。

因果验证 (Ablation)：

- Overlap Top-k（仅优化交集 token）→ 匹配完整 Student Top-k 的性能
- Non-Overlap Top-k（优化对称差集 token）→ 显著更弱

自增强动力学（解释为什么低初始 overlap 的训练会陷入停滞）：

反向同理：低初始 overlap → 梯度信号弱 → overlap 无法提升 → 训练停滞。

发现四：两种恢复策略

策略 1：Off-Policy Cold Start

策略 2：Teacher-Aligned Prompt Selection

粒度	做法	效果
Template 对齐	改用教师后训练的 prompt 模板（如 <code>\boxed{}</code> 替代 "Answer: "）	三项 benchmark 提升 + overlap ratio 提升
Content 对齐	使用教师后训练数据中的 prompt	效果更强

风险警告：Teacher-aligned prompts 会降低学生训练时的 entropy——建议混合分布外 prompt 维持探索能力。

发现五：OPD “免费午餐”的代价——长序列不可扩展

核心实验：在 0.5K 到 15K 六种最大生成长度下训练 OPD。

发现：

- 中等长度（3K, 7K）是最优区间
- 超过（10K, 15K）→ 性能平台化或下降
- “后期崩塌”：Overlap Ratio 急剧下降，学生 Entropy 和梯度范数飙升
- 崩塌从后往前传播：高 entropy 首先出现在响应末尾 → 逐步向前扩散

教师延续能力随前缀深度单调退化：

前缀长度	教师准确率优势
1K	+0.37
4K	+0.21
8K	+0.11
16K	+0.02（几乎消失）

“全局信息量 ≠ 局部可利用性”（最关键的理论洞察）：

- 成功和失败的教师都产生与 rollout 正确性相关的 token 级奖励（AUROC 0.73 vs 0.75，接近）
- 但失败的 7B 教师的奖励景观在学生策略周围是局部平坦的 → token 级梯度无效
- 假设：大教师的 per-token advantage 在序列内各向异性（anisotropic），梯度聚合时相互抵消

结论：OPD 在长序列场景下可能无法干净扩展。这对 extended CoT、agentic multi-turn 等场景提出了根本性挑战——token 级 OPD 在长链上不是效率问题，而是可能根本不 work。

该论文对 OPD 研究方向的影响

这五个发现共同指向一个方向：token 空间本身是 OPD 的瓶颈。

- Token 级 OPD 的三个天花板：
1. 只有 ~3% 的 token 参与学习（97-99% 概率质量发现）

2. 教师在长序列上不可靠（+0.37 → +0.02）

3. 更大模型不一定是更好的教师（分布不可区分性）
- Latent Space OPD 的三个对应机会：
1. 连续 latent space 没有离散 token 集 → 100% 的表示维度参与学习

2. Latent 推理天然适合压缩长链 → 降低有效序列长度

3. Latent 表示可能提取与模型规模无关的推理结构

3.3.2 论文7 详解：OPD 的三类失败模式与修复路径

论文：Fu et al., “Revisiting On-Policy Distillation: Empirical Failure Modes and Simple Fixes” 链接：<https://arxiv.org/abs/2603.25562> | 博客：<http://yuqianfu.notion.site/revisiting-opd> | 代码：https://github.com/hhh675597/revisiting_opd 作者：Yuqian Fu, Haohuan Huang, Kaiwen Jiang, Jiakai Liu, Zhuo Jiang, Yuanheng Zhu, Dongbin Zhao 时间：2026 年 3 月

这篇论文与论文5（Tsinghua）互补：论文5 回答了”OPD 什么时候成功、为什么成功”，这篇回答了”OPD 什么时候失败、为什么失败、怎么修”。两者共同构成了理解 OPD 机制的完整图景。

理论分析：Token 级 OPD 的 Bias–Variance Tradeoff

OPD 的标准实现是 sampled–token OPD——对每个采样到的 token 计算 reverse KL 的 log–ratio。但作者指出，这在理论上存在根本性的 tension：

	Sequence-Level Reverse KL	Token-Level (Sampled) OPD
偏差	无偏 (Unbiased)	有偏 (Biased) ——将分布匹配退化为单 token 信号
方差	高方差 (worst-case bound 宽松)	低方差 (更紧的 worst-case bound)
实践后果	理论上正确但不稳定	实践中可用但信号脆弱

Future–Reward Coupling 分析（受控合成实验）：

核心发现：future–reward coupling 越强 → 梯度方差越高 → 学习越不稳定。

含义：当前 token 的选择对远期 reward 的影响越大

→ 单 token 的 log–ratio 信号越不可靠

→ 在长推理链中，早期 token 的信号几乎被噪声淹没

→ 解释了为什么 OPD 在长序列上特别脆弱

三类典型失败模式

失败模式 1：不平衡的单 Token 信号 (Imbalanced One–Token Signal)

Sampled–token OPD 在每个位置只评估一个 token（实际采样到的那个）

→ 信号集中在高频 token（占概率质量 97–99%，论文5 验证）

→ 长尾但关键的低频推理 token（如数学符号、逻辑连接词）几乎收不到梯度

→ 学生学会了"看起来像在想"但没学会"真正在想"

失败模式 2：教师引导在学生生成前缀上不可靠

这是所有 OPD 变体共同面临的核心矛盾：

学生自行生成 rollout

- 随着生成进行，前缀逐渐漂移到教师很少访问的区域
- 教师在这些 OOD 前缀上的 log-prob 评估越来越不可靠
 - 教师给出"垃圾反馈"
 - 学生被垃圾反馈引导，漂移加速
 - 恶性循环 → 训练崩塌

关键洞察：这不是教师的错，也不是学生的错——是 OPD 的结构性矛盾。学生必须走到新区域才能进步，但教师在新区域无法提供可靠指导。

失败模式 3：Tokenizer / 特殊 Token 不匹配失真

不同模型的 tokenizer 行为不一致：

- <think>, </think>, <|assistant|> 等特殊 token
- 数字的分词方式 ("123" vs "1" "2" "3")
- 代码缩进、换行符的处理

- 教师和学生对这些 token 的概率评估天然不可比
- 直接计算 KL 在这些位置引入虚假的梯度信号

修复方案：Teacher Top-K Local Support Matching

作者提出了一套组合修复策略，核心思想是限制对齐范围，只在对齐有意义的地方做对齐：

组件 1：Truncated Reverse-KL

标准 Reverse KL：在整个词表 V 上计算 $KL(\text{学生} || \text{教师})$

Truncated Reverse KL：只在教师支持的 token 集合上计算

做法：在每个 prefix，取教师 top-K token，重归一化后计算 KL

效果：排除教师几乎不会生成的 token → 去噪声

组件 2：Top-p Rollout Sampling

组件 3：Special-Token Masking

组合效果：

在单任务数学推理和多任务 agentic+math 训练中，该方案实现了 +19.8% 的性能提升 (vs 标准 sampled-token OPD)，且优化稳定性显著改善。

与论文5（Tsinghua）的互补关系

维度	论文7 (Fu et al.)	论文5 (Li et al., Tsinghua)
核心问题	OPD 为什么失败？怎么修？	OPD 什么时候成功？机制是什么？
理论贡献	Bias-Variance Tradeoff + Future-Reward Coupling	两个成功条件 + 分布不可区分性
关键发现	三类失败模式（信号不平衡、教师不可靠、tokenizer 不匹配）	Token 级机制（97-99% 概率质量、overlap 自增强）
修复方案	Teacher Top-K Local Support Matching（截断 reverse KL + top-p 采样 + 特殊 token masking）	Off-Policy Cold Start + Teacher-Aligned Prompt Selection
共同指向	Token 空间本身是 OPD 瓶颈 → Latent space 可能绕过这些失败模式	同左——长序列崩塌 + 分布不可区分性 → 需要超越 token 的对齐方式

该论文对研究方向的影响

失败模式 2（教师引导在学生前缀上不可靠）是 latent OPD 最强有力的 motivation：

Token 空间的矛盾：

学生必须在自己的分布上采样（on-policy）

→ 但教师的 token 级反馈只在教师分布附近可靠

→ 学生越进步（分布变化越大），教师越不可靠

→ 这是一个内在矛盾

Latent Space 的可能出路：

→ 连续 latent 表示天然比离散 token 更平滑

→ 即使学生的 latent state 偏离教师，教师的 latent 反馈仍然有意义

→ "漂移到 OOD" 在连续空间中可能是一个渐变而非突变

3.3.3 论文12 详解：G-OPD —— 超越教师边界的广义 OPD 框架

$$J_{G-OPD}(\theta) = \max_{\theta} E_{\{x \sim D, y \sim \pi_{\theta}\}} [\lambda \cdot \log \pi_{\theta}(y|x) / \pi_{ref}(y|x) - D_{KL}(\pi_{\theta}(y|x) || \pi_{ref}(y|x))]$$

↑

奖励缩放因子 λ

↑

灵活的参考模型

参数	标准 OPD	G-OPD	含义
λ	1 (固定)	可调	控制奖励相对 KL 的权重（对应 RL 中的 $1/\beta$ ）
π_{ref}	任意（被 cancels out）	任意（有实际影响）	定义隐式奖励的基线

最优解形式：

$$\begin{aligned} \log \pi_{\theta}(y|x) &= \lambda \cdot \log \pi_{\theta}(y|x) + (1-\lambda) \cdot \log \pi_{ref}(y|x) \\ &= \log \pi_{\theta}(y|x) + (\lambda-1) \cdot (\log \pi_{\theta}(y|x) - \log \pi_{ref}(y|x)) \end{aligned}$$

这揭示了 λ 的三种工作区间：

三、ExOPD ($\lambda > 1$)：超越教师边界

这是论文最惊人的发现。

直觉：当 $\lambda > 1$ 时，G-OPD 不仅要求学生匹配教师，还要求学生额外放大教师相对于参考模型的优势方向：

这意味着学生在教师已经很好的 token 上更加确信，在教师也不确定的 token 上更加远离——学生放大教师的偏好，实现”比教师更教师”。

实验结果（Multi-Teacher Distillation）：

Teacher: Qwen3-4B-Non-Thinking 的领域特化 RL 变体 (Math / Code 两个 teacher)

- Teacher (Math): 46.0 → ExOPD: 48.0 (+2.0, 50 步)
- Teacher (Code): 61.2 → ExOPD: 62.1 (+0.9)

对比 continued RL——”不是教师训得不够”：

方法	Steps	Avg Acc
Teacher (Qwen3-4B-RL-Math)	—	46.0
Teacher + 继续 RL 100 步	100	46.9 (+0.9)
ExOPD	50	48.0 (+2.0)

给教师额外 100 步 RL 训练只带来 +0.9，ExOPD 用一半步数带来 +2.0——增益来自 reward extrapolation 机制本身，不是”教师训得不够”。

λ 的敏感度：

λ	效果
0.25, 0.5, 0.75	学生行为介于 π_{ref} 和 π^* 之间（已验证） [verified: 论文 Fig 3]
1.0 (OPD)	匹配教师但不超过
1.25	一致最优，所有实验均使用此值
1.5	可能不稳定——过度放大隐式奖励噪声，学生可能 reward hack

论文建议：固定 $\lambda = 1.25$ ，无需逐任务调参。

四、Reward Correction：强→弱蒸馏中的奖励修正

在 strong-to-weak distillation 中， π_{ref} 有两个选择：

核心逻辑：

- $\log \pi^*/\pi_{\text{teacher_base}}$ = 教师通过 RL 学到的”真正增量”
- $\log \pi^*/\pi_{\text{student_base}}$ = 教师增量 + (学生 base - 教师 base) 的交叉项 = 含噪声
- 在 strong-to-weak 设置中，学生比教师弱 → 学生 base 与教师 base 存在知识差距
→ 默认奖励混入了这个差距的噪声

Strong-to-Weak 结果 (Teacher: Qwen3-30B-A3B-Instruct-2507 → Student)：

Reward Correction 的额外收益 (Teacher: Qwen3-4B-RL → Student: Qwen3-1.7B)：

Reward correction 一致提升，但代价明确：

需要访问教师的 pre-RL variant (开源模型通常有，闭源模型没有)

$\pi_{\text{teacher_base}}$ 比 $\pi_{\text{student_base}}$ 更大 → 计算 log-prob 成本更高

五、ExOPD 训练动态

对比 OPD 的训练曲线：

Training Reward: ExOPD > OPD (验证 reward extrapolation 确实提供了更强学习信号)

Response Length: ExOPD > OPD (生成更长回复，隐式奖励可能存在长度偏差)

Entropy: ExOPD > OPD (更高多样性，由更长的回复自然带来)

六、与其他论文的互补关系

维度	论文12 (Yang et al.)	论文5 (Li et al., Tsinghua)	论文7 (Fu et al.)
核心问题	如何超越教师边界?	OPD 什么时候成功?	OPD 为什么失败? 怎么修?
理论贡献	OPD = $\beta=1$ RL; 引入 λ 和 π_{ref} 两个新自由度	两个成功条件 + 分布不可区分性	Bias-Variance Tradeoff + Future-Reward Coupling
关键发现	$\lambda>1$ 的外推可以超越教师; π_{ref} 选择影响奖励质量	97-99% 概率质量; overlap 自增强; 长序列崩塌	三类失败模式及 Teacher Top-K Local Support Matching 修复
与 latent OPD 的关联	λ 与 latent compression 率可能存在统一框架——都是一种“强度调节器”	Token 空间瓶颈 → 需要 latent	Token 空间失败模式 → 需要 latent

七、该论文对研究方向的影响

- 1. 超越教师边界现在有了理论和实验依据：ExOPD 证明了”学生超越教师”不仅可能，而且在 multi-teacher 设置中是唯一可行方案——这与论文5 (Tsinghua)”更大≠更好教师”形成互补：教师不必更大，学生也未必不能超越 [opinion]
- 2. Multi-Teacher + ExOPD 的组合为方向三 (Thinking-Pattern 自适应压缩) 提供了新可能性 [opinion]：多个领域教师 ——ExOPD——→ 统一学生 (超越所有教师) ↓ 如果 latent compression 能消除跨域教师间的 thinking-pattern 差异 → ExOPD 的 reward extrapolation 在 latent space 中可能更有效
- 3. Reward Correction 的思路暗示了参考模型选择的关键性：在 latent OPD 中，用教师 base model 的 latent representation 还是学生 base model 的作为参考？这个选择可能与 token 空间中的 reward correction 一样重要 [opinion]
- 4. λ 与 latent compression 率的理论对应[opinion]：Token 空间: λ 控制”学多少额外的东西” (extrapolation strength) Latent 空间：压缩率控制”保留多少信

息" (compression strength) → 两者都是一种"强度调节器", 可能存在统一的理论框架

5. G-OPD 的隐式奖励公式可以直接迁移到 latent space[opinion]: Token 空间: $r_t = \log \pi^*(y_t|x, y_{<t}) - \log \pi_{ref}(y_t|x, y_{<t})$ Latent 空间: $r_{step} = \text{MSE}(\ell_{student}, \ell_{teacher}) - \text{MSE}(\ell_{student}, \ell_{ref})$ → 用 latent 距离替换 log-prob 差值, ExOPD 可以在 latent space 中运行

3.3.4 论文13 详解：异步 Agentic RL 中缺失的旧 Logits——离线策略修正的语义失配与修复

论文：Guan et al., “Missing Old Logits in Asynchronous Agentic RL: Semantic Mismatch and Repair Methods for Off-Policy Correction” (arXiv:2605.12070, 2026.05) 单位：天津大学 · 清华大学 · 北京大学 · JDT AI Infra 代码：
<https://github.com/millioniron/ROLL>

核心贡献

这篇工作揭示了现代大规模异步 Agentic RL 系统中一个隐蔽但关键的工程问题：当 rollout 生成与梯度优化在物理上分离时，训练侧的历史 logits (old logits) 可能因版本滞后而丢失，导致 off-policy correction 的语义分解失效。论文从工程和算法两个层面提出了精确恢复和低成本近似的完整方案。

一、问题背景：异步 RL 中的”Missing Old Logits”

效应	英文名	含义
训练-推理差异	Training-Inference Discrepancy	同一模型版本在推理侧和训练侧因数值精度、量化、路由差异而产生不同分布
策略陈旧	Policy Staleness	异步 rollout 队列、部分轨迹收集、多次参数更新使 rollout 使用的策略版本滞后于当前 actor

核心矛盾——重要性比率的语义分解：

在理想情况下，PPO 的总重要性比率应分解为两个语义独立的因子：

$$r(\theta) = \pi_\theta(y|x) / \mu_{old}(y|x) = r_d \times r_s$$

$r_d = \pi_{old}(y|x) / \mu_{old}(y|x)$

$r_s = \pi_\theta(y|x) / \pi_{old}(y|x)$

← 训练-推理差异修正 (Discrepancy Repair)

← 策略陈旧修正 (Staleness Correction)

问题出现：当 rollout 版本 old 已过时，训练侧 π_{old} 可能已被丢弃——这就是 Missing Old Logits 问题。此时 r_d 和 r_s 都无法精确计算，两个语义被纠缠到一个 proxy ratio 中：

现有的训练框架（Verl, ROLL, SLIME）都没有解决 old-logit mismatch 问题。

二、核心理论洞察：插值代理只是重参数化裁剪边界

论文通过统一分析证明了一个关键结论：

Proposition 1: 如果 π_{prox} 通过算术插值 (linear_prox) 或 token-wise log-linear 插值构造，则对分解比率做 clipping 和 masking 只是对单个总比率 $r(\theta) = \pi_{\theta}/\mu_{old}$ 的有效约束边界的重参数化——并没有恢复缺失的参考策略。

这意味着：插值 proxy 换了个形式，但本质上没有提供新的信息。这个洞察解释了为什么简单的线性插值 proxy 在实践中效果有限。

统一视角——所有 PPO 变体都是 Masked Importance Sampling：

算法	差异比率 r_d	陈旧比率 r_s	Proxy 定义
PPO-clip (标准)	1	π_θ/π_{old}	—
PPO-clip & train_infer	1	π_θ/μ_{old}	—
Decoupled PPO & train_infer	π_{old}/μ_{old}	π_θ/π_{old}	—
PPO-EWMA	1	π_θ/π_{prox}	θ_{prox} 指数移动平均
PPO-EWMA & train_infer	π_{prox}/μ_{old}	π_θ/π_{prox}	θ_{prox} EMA
linear_prox	1	π_θ/π_{prox}	$\pi_{prox} = \alpha \cdot \mu_{old} + (1-\alpha) \cdot \pi_\theta$
Decoupled PPO & Async	π_{async}/μ_{old}	π_θ/π_{async}	$\theta \geq async \geq old$

为什么差异修复不能替代陈旧修正：

- PPO clip 是非对称的（依赖优势符号），控制更新幅度
- 差异修复需要对称的严格约束（以 1 为中心），过滤数值噪声
- 将两者混合为单一比率 → 被迫共用阈值 → 要么过于严格（瓶颈学习），要么过于宽松（噪声累积导致崩溃）

三、精确 Old-Logit 获取：三种策略

论文设计了三种从基础设施层面恢复精确 old logits 的方案：

系统开销对比（Snapshot vs PPO-EWMA）：

指标	4B Snapshot	30B Snapshot	4B PPO-EWMA	30B PPO-EWMA
切换延迟 (s)	7	14.2	7	14.2
CPU 存储 (GB)	40	76.4	7.9	15.2
额外时间 (s)	25	150	8	34

PPO-EWMA 在所有维度的开销都远低于 Snapshot。

四、Revised PPO-EWMA：低成本近似参考策略

当精确 old-logit 获取代价过高时，论文采用改进的 PPO-EWMA 作为低成本的近似参考。

核心公式：

$$\theta_{\text{prox}}(t) = \sum_{k=0}^t \beta_{\text{prox}}^{t-k} \cdot \theta(k) \quad / \quad \sum_{k=0}^t \beta_{\text{prox}}^{t-k}$$

$r_s = \pi_{\theta} / \pi_{\text{prox}}$
 $r_d = \pi_{\text{prox}} / \mu_{\text{old}}$

← 陈旧修正 (用 EMA 参考替代 π_{old})

← 差异修正 (用 EMA 参考替代 π_{old})

两个关键改进：

1. 陈旧感知的衰减系数： $\beta_{\text{prox}} \approx W_{\text{stale}} / (W_{\text{stale}} + 2)$ ，使 EWMA 参考位于异步版本窗口的中部，避免滞后于 rollout 队列

2. 自动重置机制：当 Train-Infer Mask p_t （差异 masking 和 PPO clipping 后仍活跃的 token 比例）低于阈值 τ （默认 0.9）时，重置 $\theta_{\text{prox}} \leftarrow \theta(t)$ ，清除累积的陈旧历史，重新居中参考策略

为什么自动重置关键：没有重置时，EWMA 参考会累积过多历史状态而漂移 → Train-Infer Mask 崩塌 → 大量 token 被误杀 → 训练退化。只需少量重置事件即可恢复高 Mask 值并保留早期训练收益。

五、实验结果

主要结果（Agentic Benchmarks）：

- PPO-EWMA 在所有实用方法中一致最优，在多个指标上逼近甚至追平 Snapshot†（理想化的精确 old-logit 方案）
- 在 Qwen3-30B-A3B MoE 模型上，PPO-EWMA 的 airline pass@4 达到 82，超过 Snapshot† 的 80
- Exact recovery (Snapshot†) 是最强参考线，但 PPO-EWMA 提供了最佳的性能-开销权衡

阈值分析：

- 较松的差异阈值保留更多 token，加速早期学习但可能引入偏差 token
- 较严的阈值启动慢，但后期更稳定
- 差异 masking 和 PPO clipping 仍然耦合——即使有 exact old logits，两者通过最终活跃 token 集合交互

六、与其他论文的互补关系

七、该论文对研究方向的影响

1. OPD 的异步部署可行性[opinion]: OPD 在大规模部署时同样需要异步 rollout + 训练分离——Missing Old Logits 问题直接适用。如果教师的 log-prob 计算依赖特定版本而该版本已被覆盖, OPD 的 reverse KL 计算将同样面临语义失配
2. PPO-EWMA 的思路可迁移到 OPD[opinion]: OPD 标准: $KL(\pi_\theta \parallel \pi^*)$ OPD-EWMA: $KL(\pi_\theta \parallel \pi^*_{prox})$, 其中 π^*_{prox} 是教师 logits 的 EMA $\rightarrow$ 当教师版本不可用时, 用 EMA 教师作为替代参考
3. r_d 和 r_s 的语义分离对 latent OPD 的参考设计有启发[opinion]:
 - 在 latent space 中, 差异修正 (训练-推理 latent 表示差异) 和陈旧修正 (latent state 随训练步数的漂移) 同样需要不同的约束强度
 - 不应使用单一的 MSE 阈值同时处理两种效应
1. 自动重置机制可用于 latent OPD[opinion]: 当 latent space 中的 Train-Infer Mask (等价于 latent representation 的 cosine similarity 阈值) 过低时, 重置 latent reference 到当前步——防止 latent reference 漂移

3.4 仍未解决的问题

3.5 OPD 与其他技术的关系

OPD 与 RL 的分工：

- RL = 搜索（在已有策略空间中随机变异, ”碰运气”发现新策略）
- OPD = 教学（一旦好策略被发现， 廉价高效地教会其他模型）
- RL 更偏向搜索新策略， OPD 更偏向把已发现的策略分布迁移给目标模型；
“DeepSeek-V4 用 OPD 替代 mixed RL”这一说法未能核验， 本文不再采用。

OPD 与 Latent Space Reasoning 的结合机会：

- Latent OPD 直接解决 token 空间的 97–99% 瓶颈
- 多步 latent rollout 可能解决长序列崩塌
- Latent CKA 可能弥合 thinking–pattern 不兼容问题
- 详见：研究方向_Latent_OPD.md

04 完整参考文献与链接

博客 / 综述 / 在线资源

#	标题	链接	时间	说明
B1	Thinking Machines Lab: On-Policy Distillation	thinkingmachines.ai/blo...	2025.10	最全面的 OPD 工程实践指南, 本文核心来源
B2	Penaloza et al.: Understanding Self-Distillation and Privileged Information Distillation	emilianopp.github.io/Pr...	2026.02	Forward KL vs Reverse KL 的最佳入门 (本文 Preliminary 来源)
B3	AwesomeOPD (GitHub)	github.com/thinkwee/Awe...	持续更新	OPD 论文与技术报告合集
B4	Awesome Latent Space Reasoning	github.com/YU-deep/Awes...	持续更新	Latent space 推理论文合集

创始论文 (OPD 思想源头)

#	论文	链接	会议/时间	贡献
P1	Ross et al., "A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning" (DAGGER)	arxiv.org/abs/1011.0686	AISTATS 2011	OPD 的思想源头：交互式模仿学习 + on-policy 数据聚合
P2	Agarwal et al., "On-Policy Distillation of Language Models: Learning from Self-Generated Mistakes" (GKD)	arxiv.org/abs/2306.1364...	ICLR 2024	OPD 开创性工作：将 DAGGER 移植到 LLM KD，引入 on-policy + reverse KL
P3	Gu et al., "MiniLLM: On-Policy Distillation of Large Language Models"	arxiv.org/abs/2306.0854...	ICLR 2024	Reverse KL 在 LLM 蒸馏中的首次系统分析

模型技术报告与工程案例（OPD 证据只限说明列）

#	模型	链接	时间	OPD 用法
T1	Gemma 2 (Google)	arxiv.org/abs/2408.0011...	2024.07	工业 KD 背景：报告明确使用大教师蒸馏小模型，但不强称为 OPD
T2	Qwen3 (Alibaba)	arxiv.org/abs/2505.0938...	2025.05	分水岭报告：首个系统性阐述 Strong-to-Weak OPD，仅 1% GPU 时间达 RL 同等性能
T3	MiMo-V2-Flash (Xiaomi)	arxiv.org/abs/2601.0278...	2026.01	MOPD（多教师 OPD）公开案例；GitHub: github.com/XiaomiMiMo/M...
T4	GLM-5 (Zhipu)	arxiv.org/abs/2602.1576...	2026.02	技术报告存在；未能核验原文所称 Cross-Stage OPD，故仅作相关背景
T5	Qwen3.5-Omni (Alibaba)	arxiv.org/abs/2604.1580...	2026.04	技术报告存在；未能核验原文所称 OPD 第二阶段训练，故不作为 OPD 证据

OPD 机制分析与改进（学术论文）

#	论文	链接	时间	核心发现
三 目录				
A1	Li et al., "Small Models Struggle to Learn from Strong Reasoners"	arxiv.org/abs/2502.1214...	ACL 2025	≤3B 模型从长 CoT 蒸馏反而退步，Mix Distillation 方案
A2	Yin et al., "Data Shifts Hurt CoT: A Theoretical Study"	arxiv.org/abs/2506.1064...	2025.06	首次理论证明 distribution shift 下 CoT 比不推理更差
A3	Shen et al., "Merge-of-Thought Distillation"	arxiv.org/abs/2509.0881...	2025.09	不同学生需要不同教师，不存在万能教师 CoT
A4	Jin et al., "Entropy-Aware On-Policy Distillation of Language Models"	arxiv.org/abs/2603.0707...	2026.03	Reverse KL 导致 mode collapse, entropy-aware 自适应方案
A5	Wu et al., "Rethinking Kullback-Leibler Divergence in Knowledge Distillation for Large Language Models" (AKL)	arxiv.org/abs/2504.0265...	COLING 2025	自适应组合 Forward + Reverse KL

A6	"Reasoning Path Divergence"	arxiv.org/abs/2510.2612...	2025	提出 RPD 度量化 CoT 推理路径间的语义距离
A7	Fu et al., "Revisiting On-Policy Distillation: Empirical Failure Modes and Simple Fixes"	arxiv.org/abs/2603.2556...	2026.03	OPD 三类失败模式：不平衡单 token 信号、教师引导不可靠、tokenizer 不匹配
A8	Li et al. (Tsinghua), "Rethinking On-Policy Distillation of Large Language Models: Phenomenology, Mechanism, and Recipe"	arxiv.org/abs/2604.1301...	2026.04	OPD 机制最系统分析：两条件、分布不可区分性、97-99% 概率质量、长序列崩塌
A9	Song et al., "A Survey of On-Policy Distillation for Large Language Models"	arxiv.org/abs/2604.0062...	2026.04	OPD 综述：三维分类法 + 开放问题

A10	MAD-OPD: Breaking the Ceiling in OPD via Multi-Agent Debate	arxiv.org/abs/2605.0134...	2026.05	多教师辩论驱动 OPD，突破单 教师能力天花板
A11	Lightning OPD: Efficient Post- Training for Large Reasoning Models with Offline On- Policy Distillation	arxiv.org/abs/2604.1301...	2026.04	完全离线 OPD，预计算 教师监督以降低 训练开销
A12	Luo et al., "Demystifying OPD: Length Inflation and Stabilization Strategies for Large Language Models"	arxiv.org/abs/2604.0852...	2026.04	分析 OPD length inflation，并给 出稳定化策略
A13	SCOPE: Signal- Calibrated On- Policy Distillation Enhancement with Dual-Path Adaptive Weighting	arxiv.org/abs/2604.1068...	2026.04	双路径自适应加 权 / sample- conditioned OPD 改进

A14	Yang et al., "Learning beyond Teacher: Generalized On-Policy Distillation with Reward Extrapolation" (G-OPD / ExOPD)	arxiv.org/abs/2602.1212...	2026.02	OPD = $\beta=1$ RL 特例；引入 λ 和 $\pi_{ref} \rightarrow G$ -OPD 框架；ExOPD ($\lambda>1$) 唯一能超越所有领域教师；Reward Correction 提升 strong-to-weak 蒸馏
A15	Guan et al., "Missing Old Logits in Asynchronous Agentic RL: Semantic Mismatch and Repair Methods for Off-Policy Correction"	arxiv.org/abs/2605.1207...	2026.05	异步 RL 的 old-logit 缺失→重要性比率语义分解失效；三种精确恢复策略；Revised PPO-EWMA 低成本近似；代码 github.com/millioniron/...

Privileged Information + Self-Distillation 系列

#	论文	链接	时间	核心发现
S1	Penaloza et al., "Privileged Information Distillation for Language Models" (π -Distill)	arxiv.org/abs/2602.0494...	2026.02	Forward/Reverse KL 理论基础, Reward-Tilted Distillation, Variational EM $\rightarrow$ π -Distill, 本文 Preliminary 核心来源
S2	Shenfeld et al., "Self-Distillation Enables Continual Learning"	arxiv.org/abs/2601.1989...	2026.01	自蒸馏防止遗忘, 持续学习框架
S3	Zhao et al., "Self-Distilled Reasoner"	arxiv.org/abs/2601.1873...	2026.01	On-policy self-distillation for reasoning
S4	Hübotter et al., "Reinforcement Learning via Self-Distillation"	arxiv.org/abs/2601.2080...	2026.01	Jensen-Shannon Divergence 改进纯 Reverse KL
S5	Ye et al., "On-Policy Context Distillation for Language Models"	arxiv.org/abs/2602.1227...	2026.02	On-policy context distillation

Latent Space Reasoning 相关（与 OPD 结合的前景）

RL 与一般理论

#	论文	链接	说明
R1	Levine, "Reinforcement Learning and Control as Probabilistic Inference"	arxiv.org/abs/1805.0090...	RL-as-inference 框架的经典教程
R2	Lightman et al., "Let's Verify Step by Step"	arxiv.org/abs/2305.2005...	ICLR 2024
R3	Rafailov et al., "Direct Preference Optimization" (DPO)	arxiv.org/abs/2305.1829...	NeurIPS 2023
R4	Shah et al., "A Comedy of Estimators: On KL Regularization in RL Training of LLMs"	arxiv.org/abs/2512.2185...	2026

05 一句话总结

OPD 在 18 个月内完成了从 ICLR 论文到后训练新范式的跨越。2026 年的核心命题从”要不要用 OPD”变成了”如何用 latent space / multi-teacher / adaptive KL / offline precompute 来突破 OPD 的 token 空间瓶颈和长序列限制”。

END



大模型交流群

扫码申请入群



点击下方名片 即刻关注我们



智猩猩Pro

智猩猩旗下AI产业服务账号，第一时间分享公开课-沙龙-大会信息，并为企业提供活动服...
543篇原创内容

公众号

文章推荐 · 目录

上一篇 · 【DeepSeek-V4】第 4 讲：MoE 技术细节 – 路由、FP4 Expert 与并行