

空间智能作为机器人的结构化表征

原创 Wenlong Huang human five 2026年3月3日 09:27 甘肃

1. 介绍


Wenlong Huang是斯坦福大学计算机专业博士研究生，隶属于斯坦福视觉与学习实验室（SVL），师从Fei-Fei Li教授，同时与Leslie Kaelbling、Tomás Lozano-Pérez保持紧密的合作研究。其本科毕业于UC Berkeley计算机专业，曾受Deepak Pathak教授、Igor Mordatch博士、Pieter Abbeel教授指导，还曾于UC San Diego、MIT CSAIL、NVIDIA Robotics、Google Robotics等机构开展研究工作。

Wenlong Huang

I am a Ph.D. candidate in Computer Science at Stanford, working on AI and robotics. I am advised by Fei-Fei Li as part of the Stanford Vision and Learning Lab (SVL). I'm also working closely with Leslie Kaelbling and Tomás Lozano-Pérez.


I have spent time at MIT CSAIL (2025), NVIDIA Robotics (2024), and Google Robotics (2022). I received my undergraduate degree from UC Berkeley (2018 - 2021), advised by Deepak Pathak, Igor Mordatch, and Pieter Abbeel. I also worked with Zhuowen Tu at UC San Diego as a summer intern (2018).

Email (wenlongh[AT]stanford.edu) / [Google Scholar](#) / [Twitter](#) / [GitHub](#) / [LinkedIn](#)



Follow @wenlong_huang

Wenlong Huang的研究方向聚焦于机器人学习，主攻机器人操作、基础模型与3D计算机视觉的交叉领域，围绕空间智能、机器人基础模型等方向展开深入研究，致力于开发具备结构化泛化能力的算法。其研究成果丰硕，先后斩获2023年ICRA机器人学习方向杰出论文奖、2024年CoRL LEAP研讨会最佳论文奖，多项工作入选2025年ICRA最佳论文、机器人感知最佳论文决赛名单；个人曾获斯坦福大学工程学院奖学金，还入围NVIDIA研究生奖学金、Citadel GQS奖学金决赛名单。此外，他还牵头组织了RSS、CVPR、AAAI等国际顶会的多个相关主题研讨会与教程，同时担任多个顶会顶刊的审稿人，在领域内具有较高的学术影响力。



Wenlong Huang深耕机器人学习与人工智能交叉领域多年，在机器人操作、3D世界建模、基础模型的机器人落地应用等方向取得了一系列高水平研究成果，其研发的PointWorld等核心模型为野外机器人操作的3D世界建模提供了重要解决方案，相关研究多次登上ICRA、CoRL、CVPR等国际顶会并斩获重要奖项。他的研究兼具理论深度与工程实践价值，紧扣领域核心问题与发展趋势，本次带来的机器人3D世界建模相关分享，将为大家展现该领域的前沿研究思路与实践成果，相信能为相关领域的研究者带来诸多启发与参考。

2. 开场

首先谈谈研究的初衷，在机器人领域，打造能在开放环境中作业的机器人一直是我们的核心追求。斯坦福大学机器人学个人机器人项目近20年前的一段视频，就很好地诠释了这份追求——视频中，机器人进入家居环境并完成空间整理工作。

这一成果当时令人惊艳，但其实背后是由研究生全程精准操控实现的。而对这类机器人的研究，甚至可以追溯到人工智能时代的开端，也就是人工智能概念最初被提出的时候。上世纪60年代出现的Shakey机器人，就已开启了这一研究方向的探索。

近年来，我们在该领域取得了巨大的进展，尤其是端到端策略学习方向。例如，扩散策略的广泛应用，能够高效地对多模态动作分布进行建模，其表达能力足以学习数据集中展示的各类复杂动作；同时，VLA模型也应运而生，这类模型通常由VLM微调得到，能够充分利用视觉-语言模型丰富的语义知识。

如今的技术已经发展到了一个令人惊叹的阶段：几乎所有能通过演示完成的任务，机器人策略模型都能实现学习。Physical Intelligence和TRRI团队发布的PI 0.5以及LBMS模型，就展示了诸多令人印象深刻的机器人任务完成效果。

3. 机器人学的核心挑战：数据缺口与迁移效率

但与此同时，我们也面临着严峻的数据挑战：模型虽能学习输入的所有数据，但我们究竟能为模型提供多少有效数据？Ken与K团队的一段动画演示，直观展现了若要训练出像LLM那样的前沿基础模型，机器人学领域的数据集与视觉-语言模型的数据集之间存在着巨大的缺口。

这一对比很有参考价值，但仍有一些细节值得深究。VLA模型并非从零构建，而是基于视觉-语言模型开发的。因此，我们完全有理由认为，这类模型或许并不需要海量数据——因为视

觉-语言模型已经为其赋予了关于世界运行规律的重要先验知识。


但这一观点背后，隐含着一个假设：机器人学与语言模型领域的**数据迁移效率**是相同的。显然，很少有人认同这一点，因为这是两个截然不同的领域，而目前我们尚无法对二者的迁移效率进行量化分析。

我们理想中的研究范式是：在大规模数据集上完成预训练，在测试阶段仅用少量数据，就能对模型进行微调，使其在下游任务中高效表现，最终甚至实现零样本学习。

为了量化迁移效率，我查阅了大量文献，发现OpenAI在2021年发表的一篇论文对此做了开创性研究。该研究专门量化了语言建模中的迁移效率，研究设计十分精巧：研究人员先在网络文

本数据集上对语言模型进行预训练，再针对Python程序生成任务对模型进行微调（注：该研究基于2021年的技术背景，彼时尚无GPT3，采用的是GPT2相关模型）。

需要说明的是，该研究使用的是小语言模型，目的是开展更深入的对比实验，研究团队同时声称，这一研究结论有望推广到更大规模的模型中，这一点需要大家留意。



该研究的核心结论是：在大规模数据集上完成的预训练数据量越大，模型在测试数据集上的微调效果就越好。研究团队还提出了一套量化方法：将预训练数据规模记为 s ，特定任务的微调数据量记为 D ；通过实验观察，计算出要达到相同模型性能，从零训练所需的等效数据量；将该等效数据量与实际微调使用的数据量相除，就能得到一个无量纲指标，以此量化模型的微调效率。

而在机器人学领域，若要开展此类研究，需要进行系统性的调研分析。幸运的是，TRI团队去年发布的一份技术报告，恰好针对这一研究范式，对其大型行为模型进行了细致验证。报告中的一组实验数据与语言模型领域的研究结论高度相似：预训练的数据量越大，模型在测试阶段的微调效果就越好——相同微调数据量下，模型性能更优；要达到目标性能，所需的微调数据量更少。

若我们依据OpenAI 2021年那篇论文的方法，计算机器人学领域的迁移效率，会发现一个关键结论：两个领域的模型均表现出“预训练数据量越大，迁移效果越好”的特征，但在当前TRI团队采用的预训练目标与预训练数据集下，机器人学领域的迁移效率比自然语言处理（NLP）领域低100倍。

而要让机器人学领域的迁移效率达到自然语言处理领域的水平，需要将预训练数据量扩大至TRI团队现有数据量的74000倍，这相当于1.25亿小时的机器人操作数据。这一数字看似令人望而生畏，但事实上，随着大量资本涌入机器人学的学术界和工业界，这一目标并非完全无法实现。

当然，这一结论基于两个假设：其一，新增的每一份数据，都能为预训练带来与现有数据集同等水平的多样性（现有数据集本身已是整个领域的研究成果汇总）；其二，TRI团队的微调研究仅针对桌面仿真任务，而机器人实际需要完成的任务远不止于此，这类模型在其他任务中的迁移效果，目前尚不可知。但这仍是首个对机器人学与其他领域（如NLP）的研究范式差异进行量化分析的成果。

4. 世界模型的核心优势

对于学术界而言，1.25亿小时的数据集或许在工业界具备可行性，但我们更需要思考的是：如何通过技术创新提升机器人学的迁移效率？其中一个核心假说就是**世界模型**，接下来我将通过对比，说明为何世界建模与语言模型预训练中的下一个词预测任务具有更高的相似性。

首先需要明确**世界建模**的定义，目前这一术语的使用较为泛化，在我看来，其定义十分清晰：输入当前状态与当前动作，模型输出下一时刻的状态。与之相对，策略模型的输入是当前状态，输出是当前动作。这里我并未严格区分“观测”与“状态”，是为了简化研究框架；若需严谨区分，此处的“状态”实际应为“观测”。

一个优秀的预训练目标，核心特征之一是与**测试阶段的任务目标完全解耦**。以语言模型为例，其预训练目标是下一个词预测，而在下游任务中——无论是问答、机器翻译还是文本摘要，这些自然语言处理领域的经典任务，均能被下一个词预测这一预训练目标所涵盖。

世界建模同样具备这一特征：即便尚未明确下游任务，世界建模也能让模型学习世界的运行规律。例如，儿童玩玩具、人们转笔、扔水瓶的行为，都能让我们感知世界的物理规则，而这些行为本身并无明确的任务目标。

此外，语言模型能够从多样化的非专家数据中学习，优质数据（如书籍、代码）与普通数据（如日常闲聊）均可纳入预训练数据集（未来这类数据的使用或许会有规范，但目前均被广泛采用）。

与之类似，机器人学的世界建模也能整合多类型数据：既包括高质量的演示数据，也能纳入不同载体的操作数据——比如机器狗、人形机器人的操作数据，或是人类第一视角的操作数据。

而策略模型的预训练则截然不同，其只能基于专家数据学习，因为这类数据代表了高质量的行为模式，且数据采集过程中，人类通常带有明确的任务目标。

还有一个容易被忽视的点是**模态的统一性**。在语言模型或自然语言处理领域，无论何种数据、何种任务，所有的状态与动作都能以文本形式表征，无需刻意区分状态与动作。即便在语言模型中开展强化学习研究，即便能从形式上定义状态与动作，二者的文本表征形式也让这种区分失去了实际意义。

但在机器人学领域，我们面临着模态碎片化的难题：观测空间与动作空间均高度多样化。观测空间方面，目前学界基本达成共识，视觉信息是核心输入（其他模态信息虽有帮助，但并非必需），因此观测空间的定义相对清晰；而动作空间则完全不同，不同机器人的自由度千差万

别，即便自由度相同，机械爪的几何结构（如手指长短）也会极大影响机器人的行为模式，这为统一的预训练带来了巨大挑战。

由此引出一个核心问题：机器人学能否实现模态的统一？这也是我今天要重点分享的内容，此外，还有一个重要且研究较少的切入点：**世界模型能够通过测试阶段的推理，生成超出训练数据范畴的解决方案或行为模式。**

这一特性的重要性体现在：目前机器人学领域推崇从演示中学习，但Rich Sutton提出的“苦涩的教训”核心并非单纯的学习，而是**学习与搜索的结合**。语言模型的发展也印证了这一点：学习（即规模化预训练）至关重要，但仅靠下一个词预测无法支撑模型的实际应用，还需要规模化的测试阶段计算，让模型针对具体场景进行推理。

即便在语言模型领域，我们也无法将所有场景的解决方案都压缩到预训练或离线训练中，测试阶段的推理是生成解决方案的关键，尤其是针对全新场景。而机器人学的难度远超自然语言处理，因此更不可能在训练阶段覆盖所有场景。

我非常认同加州大学伯克利分校Sergey Levine教授的一张示意图，这张图在“苦涩的教训”基础上，对比了学习与搜索的核心作用：学习是通过数据提取规律，搜索是通过计算推导推理结果；学习让我们理解世界，而搜索则能基于这种理解实现行为的涌现。

这一逻辑对机器人学至关重要，Physical Intelligence团队的精彩演示就证明了这一点：机器人能完成复杂任务并生成创新解决方案。例如，机器人仅有夹爪式机械手，无法像人类一样

翻转袜子，因此它会将袜子套在夹爪上实现翻转；又如，机器人没有多指手，因此会将塑料袋按在桌面上完成开袋动作。

这些都是极具创新性的解决方案，但均由人类演示者设计，是人类智慧的体现。那么，如何让机器人在测试阶段自主生成这类涌现行为？核心答案就是**世界模型**——它能支持“假设性”查询，让机器人推理不同动作对环境的改变，进而自主生成解决方案。

5. 核心研究工作：PointWorld——面向野外机器人操作的3D世界模型规模化

以上是本次研究的背景与初衷，接下来进入核心研究内容——**PointWorld：面向野外机器人操作的3D世界模型规模化**。这项研究是我博士阶段18个月的核心工作（实际核心研发耗时12

个月)，也是我主导的唯一一项研究，我们认为其具有重要的研究价值，因此投入了大量时间打磨，力求达到理想的研究效果。

接下来我将详细介绍这项研究，首先是研究目标与模型的输入输出，整体设计十分简洁：

- **输入：**RGBD图像（单张、两张或多张均可）、目标机器人的描述信息（测试阶段可更换，例如更换机械手指，输入包含机器人的URDF模型）、一组机器人动作（世界建模的核心输入）；
- **输出：**针对该机器人载体与具体场景，模拟机器人执行上述动作后，整个场景的动态变化过程。

这里需要明确“动作”的定义：在世界建模的现有研究中，有将文本、导航指令作为动作的做法，这类做法适用于特定场景，但对于机器人操作任务而言，其粒度过于粗糙，无法支撑精细化的假设性推理。

而机器人操作领域的现有做法，通常将末端执行器位姿、关节指令作为动作：

1. 末端执行器位姿：无法表征机械爪的几何结构（如手指长短、形状），也无法处理多机械爪的场景（多机械爪会带来多个位姿，导致动作空间变化）；
2. 关节空间指令：同样无法表征机械爪几何结构，且面对自由度、运动学结构不同的机器人，该表征方式会失效。

这一问题背后，隐藏着一个关键思考：我们采集演示数据时，能轻松为不同载体的机器人采集数据，无需关注其自由度，只需聚焦任务本身与机器人的可控性。这是因为我们在采集数据时，关注的是**3D交互几何特征**，即从3D空间的角度理解动作，而非局限于特定的关节空间指令。

这也是本研究的核心切入点：**采用3D表征机器人动作**，最终我们选择了**3D流**作为动作表征方式，其核心优势是**载体无关的动作空间**——能轻松适配不同载体、不同几何结构、不同运动学结构的机器人，无论是机械手的几何差异，还是机械手的数量差异，都能通过同一动作空间表征，且模型架构对3D流的点数量具有不变性。

3D动作流的生成方式：无需额外学习，基于机器人的URDF模型与网格模型，在机器人的每个连杆上采样端点，通过正运动学计算，将各连杆的端点变换为点流，即得到动作的3D流表征。

为了实现预训练的模态统一，我们将3D流表征同样应用于**状态**：场景状态由RGBD图像构建的静态点云表征，结合机器人的URDF模型，通过解析计算得到机器人的3D点流，二者共同作为模型输入。

模型的核心预测目标是**场景的未来动态变化**，其整体架构设计如下：将机器人的3D点流与场景静态点云直接拼接为一个整体点云，输入至点云Transformer模型**PTV3**，模型输出整个场景的3D流（即场景中所有点的运动轨迹）。

这一模型架构看似简洁，却能捕捉机器人操作任务所需的多项核心特性，且所有特性均为模型**隐式学习**（无额外的显式模块设计）：

1. **3D目标检测与分割**：模型无需输入分割掩码，需自主识别被操作的目标物体；
2. **材料属性估计**：基于预训练数据，模型能区分可变形物体（如布料）的变形规律、铰接物体（如冰箱）的铰接结构，无显式的铰接结构估计模块；
3. **形状补全**：面对大型物体（如箱子），模型只能观测到部分区域，需通过形状补全支撑机械手与物体的接触推理；
4. **物体间动态交互推理**：模型能处理多物体叠加的场景（如机械手托着装有物体的碗），推理物体间的接触与运动规律；
5. **重力与可变形性融合**：模型能同时捕捉重力的影响与物体的可变形特征，还原真实的物理交互过程。

我们在研究网站上发布了大量模型推演的视频案例，大家可以自行查看，这里选取几个**未出现在训练数据中的全新案例**（所有案例均由同一模型检查点生成）进行展示：

1. 输入两张侧面视角的RGBD图像（来自Droid数据集），模型能精准预测机械手操作时，布料的变形与运动轨迹；

2. 上述案例的广角视角，机械手托着装有机体的碗，模型能还原碗、内部物体与机械手的协同运动；
3. 大型箱子旋转案例：模型基于机器人URDF模型采样机械手的点云，因此能观测到箱子后方的机械手，而场景本身为部分可观测，模型通过形状补全完成接触推理；
4. 未知机器人与未知场景案例：机器人抓取篮子并摇晃，篮内装有多物体，模型能精准推理物体间、物体与篮子间的接触规律，以及重力对整个过程的影响。

6. 3D世界模型的训练与规模化探索

当下是研究3D世界建模的黄金时期，此前的研究受限于数据，而如今随着3D视觉领域技术的成熟，我们已拥有足够的工具来构建高质量数据集。本研究中，我们采用了近年来3D视觉领域的多项优秀研究成果——**基础立体视觉模型VGGT**、**CodeTracker3**、**PointTransformerPTV3**，基于这些工具对Droid数据集进行标注，实现了对超60%数据集

的精准标注（包含成功与失败的操作数据），标注得到的深度信息与相机位姿达到了仿真级精度。

我们将标注结果与Droid数据集原始的深度信息、相机标定结果进行了对比（相机标定采用作者发布的最新V2版本），结果显示，新的视觉模型让深度信息与相机位姿的精度得到了大幅提升。

此外，我们还纳入了来自Behavior数据集的**大规模多样化仿真数据**，该数据集包含大量高真实感的家居环境仿真数据，是机器人学领域规模最大的仿真数据集之一。

在对所有数据进行过滤后（剔除无实际交互的静态场景数据，如机器人在空空中的运动），我们最终构建了**500小时的高精度3D交互数据集**。尽管与2D模型的训练数据量相比，这一规模仍较小，但已是目前3D机器人学领域规模最大的数据集之一，我们也期待随着3D模型技术的发展，能构建更大规模的数据集。

基于这一数据集，我们能够开展**3D世界模型的规模化研究**，并严谨分析其规模化后的特性。这里的“严谨”体现在：模型为密集预测模型，且测试集占总数据集的10%，模型预测误差的标准误可达 10^{-5} m量级（比人类头发丝还细数倍）。因此，不同模型或不同实验设置的性能对比结果极具区分度，能清晰判断优劣。

我们制定了清晰的3D世界模型规模化路线，并总结出了核心优化策略，整体优化过程与效果如下：

1. **基础模型选型**：以机器人动态建模领域主流的**基于图的神经元动态模型**为基线，采用更现代的点云架构对其进行升级；
2. **点云架构迭代**：将基线模型替换为PointNet，模型误差略有降低（适配更大规模场景）；进一步替换为最新的PTV3，模型误差大幅下降；
3. **训练目标优化**：机器人仅与场景的极小区域交互，因此需强化运动点的训练信号；同时，3D标注数据存在噪声，需加入置信度加权损失、聚焦运动区域的损失，并结合Huber损失，降低噪声标签的影响；
4. **图像特征融合**：本研究中的3D点云模型为从零训练（与2D视频模型可基于预训练模型微调不同），因此需要引入场景语义先验知识；我们尝试了DinoV2不同模型尺寸与DinoV3，发现融合DinoV3 ViTL的多层特征时，模型性能提升最显著；
5. **模型规模扩容**：为充分利用数据集的信息，模型规模的扩容至关重要。

深入分析模型骨干架构后发现，**PTV3等现代Transformer架构**的优势十分显著：在内存占用相近、计算量仅为原来1.8倍的情况下，模型规模可扩容至原始图基神经元动态模型的近300倍，这一扩容能力让模型能充分吸收数据集中的信息，大幅降低预测误差。

动作的空间表征同样是关键，我们对比了多种动作表征方式的效果，最终**仅基于机械爪的3D点流**表现最优。对比的基线方法包括：机器人全身的3D点流（500个点、3000个点）、低维表征（关节位置、末端执行器位姿）。

实验采用**跨载体训练**：模型同时在Droid数据集的Franka机器人、Behavior数据集的Galaxie R1 Pro机器人上训练（二者为差异极大的机器人载体），核心结论如下：

- 1. 关节位置表征的误差最大，末端执行器位姿表征的误差略有降低（虽二者一个为单机械手、一个为双机械手，但位姿表征与任务的对齐性更高）；
- 2. 机器人全身3D点流在仿真场景中表现优异（仿真场景无噪声，迁移效果好），但在真实场景中性能显著下降——真实场景存在大量噪声，且交互仅发生在机器人的极小区域，全身点流会分散模型对交互区域的注意力；
- 3. 仅基于机械爪的3D点流在真实场景与仿真场景中均表现最优，且实现了**不同机器人载体间的正向迁移**。

7. 模型泛化性与关键特性验证

基于上述评估体系，我们设计了多种实验设置，全面验证模型的**泛化特性**。实验仍基于Droid（记为D）与Behavior（记为B）两个数据集的跨载体训练，验证方向包括**域内泛化**、**跨域泛化**，以及**留出数据集泛化**（从Droid数据集中留出Jose实验室的数据集——该实验室位于韩国，与其他Droid研究团队地理距离最远，最大程度降低数据污染）。

我们探究了不同预训练设置下，模型在留出数据集上的泛化性能，并与针对该留出数据集单独训练的模型进行对比，同时验证了**零样本与微调**两种场景，实验数据丰富，结论颇具价值，其中最核心的结论为：

1. 基于大规模数据集预训练后，模型在真实世界未知数据上的零样本性能，几乎能与针对该数据单独训练的模型持平（实验基于Droid数据集的任务分布）；
2. 仅用5%的微调数据对预训练模型进行微调，其性能即可超越从零训练的基线模型；
3. **仿真预训练的价值**：仿真预训练能让模型在真实场景中的训练，比从零训练节省20倍的计算量，但真实世界数据仍是不可或缺的——仅依靠仿真预训练的模型，在真实场景中无法有效工作；
4. **数据与模型规模的协同效应**：模型性能随数据量增加、模型规模扩容呈**近似线性提升**（对数空间）：固定模型规模，增加训练数据量，模型性能持续提升；固定数据量，扩容模型规模，模型误差持续下降。这一规律表明，更大的数据集与更大型的模型，将进一步提升3D世界模型的性能。

本研究中，模型采用**块预测**策略：单次前向传播即可预测未来10个时间步（1秒，时间步长 $dt = 0.1$ 秒）的场景动态，这一设计的重要性与机器人策略训练中的块预测一致：

1. 减少推演过程中的累积误差；
2. 大幅提升计算效率——若采用逐时间步的回归预测，需多次前向传播才能完成长序列推演，而块预测单次前向传播即可完成1秒的推演，即便需要长序列推演，也能基于块预测进行链式拼接。

作为3D模型，**处理部分可观测性**的能力是关键，我们设计了专门的实验验证这一特性：

1. 训练四种模型：仅单相机训练、固定双相机训练、固定三相机训练、随机相机数量训练；
2. 采用二维评估矩阵：测试阶段分别采用单相机、双相机、三相机评估所有模型的性能。

核心结论：

- 1. **随机相机数量训练的模型性能最优：**该训练方式让模型适应了不同程度的部分可观测性，使其在隐式目标分割、材料属性估计时更具鲁棒性；
- 2. **多视角的信息增益：**更多的相机视角能提供更丰富的场景信息，模型性能随测试视角数量增加而提升，这一趋势在实验中表现得十分明显；
- 3. **测试阶段的鲁棒性：**模型对测试阶段的部分可观测性变化具有鲁棒性。例如，双相机训练的模型，在单相机测试时误差较高，双相机测试时误差显著下降，三相机测试时误差进一步降低。

8. 3D世界模型在动作推理中的应用

世界模型的应用场景十分丰富，可用于预训练、强化学习的环境建模、策略适配等，但本研究聚焦于世界建模本身，因此选择了**最基础的基线应用方式**——将PointWorld与**基于模型的规划**结合，**无演示数据、无微调**，验证模型的动作推理能力。

尽管展示的任务并非最复杂的，但所有行为均为模型在**测试阶段自主生成**，无针对性的训练，涵盖的场景包括：非预定义的推物任务、可变形物体操作、铰接物体操作，以及需要推理物体间动态交互的任务。

9. 研究局限性与未来研究方向

本研究仍存在诸多局限性，这些也是未来机器人学世界建模领域的重要研究方向，我们在论文中进行了详细阐述，力求研究的透明性，具体包括：

1. **静态场景假设**：模型假设初始场景为静态，其捕捉的更多是**数据的相关性而非因果性**。例如，模型会预测到训练数据中，机器人动作时背景中行人的移动，而这一移动并非由机器人动作引发，这一问题与当前多数机器学习模型的局限性一致，未来需研究如何让模型学习**因果效应**；
2. **无光度动态表征**：模型仅预测点的运动轨迹，无法捕捉光度动态变化。这使得模型无法应用于需要光度信息的任务，例如开关灯、开关电脑——这类任务需要通过光度变化判断动作是否成功；
3. **驱动与跟踪假设**：模型假设输入的动作均能被机器人精准执行，但在真实场景中，这一假设并不成立。例如，模型会接收机器人穿透墙壁、桌面的动作指令，并基于此预测场景变化，但真实机器人受限于物理规则、负载等因素，无法执行此类动作，且控制器也无法精准跟踪所有指令，这一假设偏差是模型落地的重要障碍。

10. 总结思考

本研究提出的PointWorld是一个纯世界模型，**不涉及决策制定**，其核心价值是捕捉了**物理直觉**——建立了动作与状态变化之间的关联，这也是测试阶段模型能推理并生成创新解决方案的关键。

而要实现完整的系统性推理，还需要将物理直觉与**目标描述**相结合，明确“希望让世界发生何种变化”。目前的VLM已具备一定的空间理解能力，有望实现这一目标，尽管当前的视觉-语言模型尚未达到足够的性能水平，但我们的早期研究已验证了其在目标描述中的潜力。

将**3D世界模型的物理直觉**与**视觉-语言模型的目标推理**相结合，就能形成一套完整的流水线，让机器人在测试阶段自主生成创新行为。但这一过程仅属于**系统2思维**（慢思考、逻辑推理），而机器人的自主操作还需要**系统1思维**（快思考、直觉反应），这一能力主要来自**运动直觉建模**。

目前的策略学习研究，大多聚焦于运动直觉的捕捉，但这类研究通常带有明确的任务目标，导致模型学习的运动直觉具有任务特异性。未来更合理的研究方向是：让模型在**无特定目标**的情况下捕捉运动直觉，这样才能与物理直觉、目标推理更有效地融合。

我们的研究愿景是：让**物理直觉**、**目标推理**、**运动直觉**在人类所处的**3D空间物理世界**中实现融合——将视觉-语言模型锚定到3D空间，在3D空间中进行假设性推理，同时针对目标机器人的几何结构，在3D空间中捕捉运动直觉。

11. 问答

提问者1：我了解到你们构建了一个全新的数据集，请问是否计划将其开源，供后续研究使用？

Wenlong：当然，我们每天都会收到大量索要数据集、代码与预训练检查点的邮件。该数据集是我们与英伟达的合作成果，目前正在英伟达法务团队的审核中，我们希望能尽快将其开

源。

提问者2：这项研究非常出色！你在报告中展示了世界建模的多项特性，比如铰接结构理解、重力感知等。我想请教的是，基于像素的2D世界模型也能实现一些相关功能，例如新视角合成、一定程度的3D重建，你认为2D世界模型是否也能捕捉到与3D世界模型类似的特性？

Wenlong：当然可以，这是一个非常好的问题。2D模型确实能捕捉到这些物理特性，而本研究选择3D世界建模，核心优势体现在**动作表征**上。

我与很多从事视频生成、生成式建模的研究者探讨过这一问题，生成式建模领域的研究者也十分关注**条件控制**，而这正是机器人学领域的核心需求——我们需要用机器人的具体动作，而非文本，来控制模型。

我个人的一个核心观点（甚至可以说是坚定的看法）是：**从人类的身体感知来看，动作本质上是3D的**。例如，我们能将手伸进口袋（视线无法看到口袋内部），也能闭着眼睛在3D空间中移动手臂和手掌，这种对动作的感知是天生的3D属性。

因此，我认为场景的观测与生成可以是2D的（具体取决于应用场景），但动作的表征**必须是3D的**。本研究的目标是实现动作与状态的3D模态统一，而当然，也有研究者会基于2D架构，以2D作为输入与输出，开展类似的研究。

提问者3：这是一个技术问题，也是大家经常探讨的3D与2D世界模型的对比问题。如果给定数据量相近的2D与3D数据，训练世界模型的成本会更高还是更低？

Wenlong：这是一个很好的问题，我目前无法给出确切答案。我猜你提到的“成本”，应该是指**计算效率**（因为数据量相同）。

我认为这很大程度上取决于**训练框架与模型架构**。从目前的技术现状来看，**2D模型的技术成熟度远高于3D模型**——2D模型的应用更广泛，相关的训练基础设施也更为完善，这是2D模型在计算效率上的巨大优势。

而如果谈论**学习效率**，目前同样难以量化，但我与你的观点一致：3D模型的学习效率会更高，因为**3D表征的信息密度更高**。物理世界的规律本身就是在3D空间中发生的，3D世界模型更接近物理仿真器，而2D模型更偏向渲染器——我们的3D模型实际上是在无网格的情况下，对物体的碰撞与运动进行建模。

当然，目前尚无理想的量化方法，因为二者的输出形式截然不同：3D模型输出的是3D轨迹，而2D模型的损失函数基于光度渲染，这使得二者难以进行严格的一对一对比。

欢迎“点赞”、“收藏”、“在看”三连

[阅读原文](#)