



北京大学  
PEKING UNIVERSITY

# Learning Dynamic Non-Prehensile Dexterity via Homotopic Dynamics Curriculum




汇报人：杨铠睿



2026. 1. 22





# 从动力学角度对灵巧操作的分类



## Quasi-Static

$\ddot{q} \approx 0$   
惯性力近似为零



## Force Closure

系统的自由度完全可控



## Non-Prehensile

无法直接控制系统的全部自由度

惯性力不可忽视

## Dynamic



# 不同类的任务—>系统需要学习不同的动力学特性

## Quasi-Static

惯性力近似为零

⋮

$$g(q) = F$$

学习如何在非完全可控下平衡重力

系统的自由度完全可控

Force Closure

系统自由度非完全可控

Non-Prehensile

↑

↓

非完全可控下，不总能产生用于抵消重力的分力，需要利用惯性力

← 惯性项不可忽视 →

Dynamic

This Work

利用对自由度的完全可控，  
学习用于平衡重力的分力  
和控制目标轨迹的分力

$$(M(q)\ddot{q} + C(q, \dot{q})\dot{q}) + g(q) = F = F_1 + F_2$$

# Dynamic Non-Prehensile 对应的动力学特性和难度

以Thumbaround动作为例



拇指的支持力不足以抗衡重力(保持平衡)

惯性力->产生与拇指侧的接触力->产生摩擦力分量对抗重力




系统需要在 非完全可控 下学习

发力 -> 进入高惯性状态 -> 利用惯性力/惯性力产生的力 -> 平衡重力并完成目标轨迹


# The Impacts on RL

系统非完全可控下的高惯性状态，对应的Value Landscape极其崎岖



# Methodology

Reinforcement Learning  
Value Function for Thumbaround



系统非完全可控下的高惯性状态，对应的Value Landscape极其崎岖

需要拉伸Value Landscape，提高探索到安全轨迹并跳出局部最优的可能

让系统/任务慢下来

压缩系统的速度

# Methodology

压缩系统的速度后，需要对物理参数进行相应缩放，保持动力学方程的平衡

$$M(q)\ddot{q} + C(q, \dot{q})\dot{q} + g(q) = F$$

$$\alpha \in (0, 1]$$

$$C(q, \dot{q}')\dot{q}' = C(q, \alpha\dot{q}) \cdot (\alpha\dot{q}) = \alpha^2 [C(q, \dot{q})\dot{q}]$$

同步缩放重力项、加速度项为  $\alpha^2$  倍



$$\alpha = 0.5$$

# Methodology: Guided Exploration via Homotopic Dynamics Curriculum

在低速空间学习策略后，利用 $\alpha$ 的连续性和动力学方程的平衡，将策略逐步迁移到目标空间




$$\alpha = 0.5$$

$$\alpha = 1.0$$

Homotopic Curriculum

# Case Study: Acrobatic Pen Spinning(Thumbaround & Triangle Pass)

- 高惯性状态 —> 笔的角速度极高，系统状态点在相空间中移动极其迅速
- **Non-Prehensile** —> Spin 阶段笔绕拇指背侧旋转、仅靠拇指背侧的接触维持，缺乏持续的力闭合约束。
- 利用惯性力 —> Triangle Pass的高惯性状态提供了换指的短暂窗口；Thumbaround的高惯性状态产生了指背的摩擦力




# Experiments Protocols

## Subjects

1. HDC(set  $\alpha=0.5$  for initial domain)
2. Baseline

## Tasks

1. Thumbaround
2. Triangle Pass



## Metrics

1. 是否探索到目标轨迹（成功率 $>0$ ）
2. 收敛后的成功率
3. 收敛所需时间

## Difficulty

1. Policy Frequency  
(10Hz, 20Hz)


# Experiments

|                  | Subject         | Succ.      | Time         |
|------------------|-----------------|------------|--------------|
| TA 20Hz          | HDC<br>Baseline | 97%<br>93% | 3.2h<br>5.9h |
| TA 10Hz<br>Exp.1 | HDC<br>Baseline | 73%<br>0%  | 22.7h<br>\   |
| TA 10Hz<br>Exp.2 | HDC<br>Baseline | 72%<br>42% | 15.7h<br>26h |
| TP 20Hz          | HDC<br>Baseline | 81%<br>62% | 1.8h<br>11h  |

- Advantages:
- 1. Policy Converged to Desired Task Pattern
  - 2. Higher Final Success Rate
  - 3. Faster Convergence (Curriculum Time Included)


# Discussion

## Homotopic Dynamics Curriculum 对比 Control Frequency Curriculum



CFC: 对于目标为低频的目标策略（如10Hz Thumbaround），更改Decimation使策略的观察和决策更高频

→ 相对于采样频率拉伸了Value Landscape, 提高探索到安全轨迹并跳出局部最优的可能



Decimation: 策略观察和决策间隔对应的仿真模拟次数/Controller运行次数（一般使用PD Controller）


优势1:

HDC: 利用Homotopic(连续性+动力学相似性)特性做transfer


CFC: 只能调节离散的Decimation

# Discussion

## Homotopic Dynamics Curriculum 对比 Control Frequency Curriculum



如何充分利用Homotopy特性做transfer  
当前仅使用一个success threshold, 考虑别的判据  
e.g. 达到threshold且Critic Loss (变化) 低于阈值



# Discussion

## 策略成功率指标

对于最终收敛到成功率73%的策略：

成功率最低的前 50 个初始化 ID：





| 排名 | ID   | 成功率    | 成功次数 | 总次数 |
|----|------|--------|------|-----|
| 1  | 7059 | 51.85% | 56   | 108 |
| 2  | 542  | 53.92% | 55   | 102 |
| 3  | 1105 | 56.38% | 53   | 94  |
| 4  | 5169 | 56.57% | 56   | 99  |
| 5  | 513  | 56.99% | 53   | 93  |

初始化方式：人为指定任务开始时对应的**几何形态**，经过随机扰动选择10000份可以短暂保持稳定的states作为初始化（Xiaolong Wang、Eureka等的做法）

不存在策略完全未学会的初始化状态，而是操作过程中出现了“失误”  
→低频下，Dynamic Non-prehensile任务涉及对时机的预测

# Discussion

## Low-Level Controller 对策略训练的显著影响



1. 结果具有对于Kp、Kd的依赖性
2. 关节限位限制了输出力矩能力
3. Fixed PD Control限制了力矩pattern

# Discussion

## 如何调整Low-Level Controller，在搜索空间和策略能力之间Trade-Off


- PPO 策略网络输出动作向量  $\mathbf{a}_{policy}$ ，通常是从高斯分布  $\mathcal{N}(\mu, \sigma)$  采样得到  $\mathbf{a}_{policy} \in \mathbb{R}^{d_{action}}$ 。
  - $\mathbf{a}_{policy} = \text{clamp}(\mathbf{a}_{policy}, -1, 1)$
- 应用全局动作缩放因子 `action_scale`，目标位置基于前一步目标位置更新：【AS控制】
  - $\mathbf{q}_{target}[t] = \mathbf{q}_{prev\_target} + \mathbf{a}_{policy} \times \text{action\_scale}$
- 关节限位截断：【限位控制】
  - $\mathbf{q}_{target}[t] = \text{clamp}(\mathbf{q}_{target}[t], \mathbf{q}_{abs\_lower}, \mathbf{q}_{abs\_upper})$
  - 更新 `prev_targets` 为当前目标： $\mathbf{q}_{prev\_target} \leftarrow \mathbf{q}_{target}[t]$
  - 关节限位普遍为  
lower: -1.5700  
upper: 0.0000
- 获取当前关节位置和速度，PD 力矩公式【Kp控制】
  - $\mathbf{q}[t]$ : 当前关节位置 (从 `dof_state` 获取)
  - $\dot{\mathbf{q}}[t]$ : 当前关节速度 (从 `dof_state` 获取)
  - $\boldsymbol{\tau}[t] = \mathbf{K}_p \odot (\mathbf{q}_{des} - \mathbf{q}[t]) - \mathbf{K}_d \odot \dot{\mathbf{q}}[t]$ 
    - $\odot$ : 逐元素乘法
- 力矩限位截断：【力矩上限控制】
  - $\boldsymbol{\tau}[t] = \text{clamp}(\boldsymbol{\tau}[t], -\tau_{limit}, \tau_{limit})$

1. 结果具有对于Kp、Kd的依赖性
2. 关节限位限制了输出力矩能力
3. Fixed PD Control限制了力矩pattern

Kp、Kd显著影响了Dynamic Non-prehensile任务的搜索空间和策略能力，而当前的研究普遍对真机的PD参数进行系统辨识、只训练对应的参数

# Discussion

Exploration Barrier/Risk Aversion与reward engineering的关系最大，如何设计实验



系统非完全可控下的高惯性状态，对应的Value Landscape极其崎岖

需要拉伸Value Landscape，提高探索到安全轨迹并跳出局部最优的可能

让系统/任务慢下来

压缩系统的速度